

Question N° 1

$$\mathcal{D} = \{x_i, y_i\}_{i=1, \dots, n} \text{ et } p=1$$

1-a) Détermination de l'estimateur de maximum de vraisemblance

$$f(y_i | \theta, x_i) = \begin{cases} 2(x_i \theta)^2 y_i^3 \exp\{-\theta x_i y_i^2\} & \text{si } y_i \geq 0, x_i \geq 0 \\ 0 & \text{sinon.} \end{cases}$$

$$L(\theta) = \prod_{i=1}^n f(y_i | \theta, x_i)$$

$$= \prod_{i=1}^n 2(x_i \theta)^2 y_i^3 \exp\{-\theta x_i y_i^2\}$$

$$\ell(\theta) = \ln \prod_{i=1}^n 2(x_i \theta)^2 y_i^3 e^{-\theta x_i y_i^2}$$

$$= \sum_{i=1}^n \left[ \ln(2) + 2 \ln(x_i \theta) + 3 \ln y_i - \theta x_i y_i^2 \right]$$

$$\frac{\partial \ell(\theta)}{\partial \theta} = \sum_{i=1}^n \left[ \frac{2}{\theta} - x_i y_i^2 \right]$$

$$= \frac{2n}{\theta} - \sum_{i=1}^n x_i y_i^2$$

$$\frac{\partial \ell(\theta)}{\partial \theta} = 0 \Rightarrow \boxed{\hat{\theta}_{\text{mv}} = \frac{2n}{\sum_{i=1}^n x_i y_i^2}}$$



$\frac{\partial^2 \ell(\theta)}{\partial \theta^2} = -\frac{2n}{\theta^2} < 0$ , nous sommes donc à un maximum.

• Information de Fisher

$$I(\theta) = -E \left[ \frac{\partial^2 \ell(\theta)}{\partial \theta^2} \right]$$

$$= -E \left[ -\frac{2n}{\theta^2} \right] = \frac{2n}{\theta^2}$$

Donc  $I(\theta) = \frac{2n}{\theta^2}$

La variance asymptotique de  $\theta$  est

$$V(\hat{\theta}_{\text{cvm}}) = \frac{1}{I(\theta)} = \frac{1}{\frac{2n}{\theta^2}} = \frac{\theta^2}{2n}$$

Alors lorsque  $n$  est grand on a :

$$\hat{\theta}_{\text{cvm}} \sim N\left(\theta_0, \frac{\theta^2}{2n}\right)$$



1-b) Détermination de l'estimateur de maximum de vraisemblance  $\hat{\theta}_{\text{evm}}$  de  $\theta$ .

$$D = \{x_i, y_i\} \sim \mathcal{P}(x_i, \theta)$$

$$P(y_i | \theta, x_i) = \begin{cases} \binom{y_i-1}{x_i-1} \theta^{x_i} (1-\theta)^{y_i-x_i} & \text{si } y_i = x_i, x_i+1, \dots \\ 0 & \text{sinon} \end{cases}$$

$$L(\theta) = \prod_{i=1}^n \binom{y_i-1}{x_i-1} \theta^{x_i} (1-\theta)^{y_i-x_i}$$

$$\mathcal{L}(\theta) = \ln \prod_{i=1}^n \binom{y_i-1}{x_i-1} \theta^{x_i} (1-\theta)^{y_i-x_i}$$

$$= \sum_{i=1}^n \left[ \ln \binom{y_i-1}{x_i-1} + x_i \ln \theta + (y_i - x_i) \ln (1-\theta) \right]$$

$$\frac{\partial \mathcal{L}(\theta)}{\partial \theta} = \sum_{i=1}^n \left[ \frac{x_i}{\theta} - \frac{(y_i - x_i)}{(1-\theta)} \right]$$

$$\frac{\partial \mathcal{L}(\theta)}{\partial \theta} = 0 \Rightarrow \sum_{i=1}^n \frac{x_i}{\theta} - \sum_{i=1}^n \frac{(y_i - x_i)}{(1-\theta)} = 0$$

Après transfor-  
mation et réso-  
lution d'équation

$$\hat{\theta}_{\text{evm}} = \frac{\sum_{i=1}^n x_i}{\sum_{i=1}^n y_i}$$

$$\frac{\partial^2 \mathcal{L}(\theta)}{\partial \theta^2} = \sum_{i=1}^n \left[ -\frac{x_i}{\theta^2} - \frac{(y_i - x_i)}{(1-\theta)^2} \right] < 0$$

Nous sommes donc à un maximum

• Information de Fisher

$$\begin{aligned} I(\theta) &= -E \left[ \frac{\partial^2 \mathcal{L}(\theta)}{\partial \theta^2} \right] \\ &= -E \left[ \sum_{i=1}^n \left[ -\frac{x_i}{\theta^2} - \frac{(y_i - x_i)}{(1-\theta)^2} \right] \right] \\ &= \sum_{i=1}^n \left[ E \left[ \frac{x_i}{\theta^2} \right] + E \left[ \frac{y_i - x_i}{(1-\theta)^2} \right] \right] \end{aligned}$$

$$E(y_i) = \frac{x_i}{\theta}$$

$$\text{Alors } I(\theta) = \sum_{i=1}^n \left[ \frac{x_i}{\theta^2} + \frac{1}{(1-\theta)^2} \times \left( \frac{x_i}{\theta} - x_i \right) \right]$$

$$I(\theta) = \sum_{i=1}^n \frac{x_i}{\theta^2(1-\theta)} \quad V(\hat{\theta}_{\text{cvm}}) = \frac{1}{n I(\theta)}$$

Lors  $n$  devient grand,

$$\hat{\theta}_{\text{cvm}} \rightsquigarrow N \left( \theta, \frac{1}{n \sum_{i=1}^n \frac{x_i}{\theta^2(1-\theta)}} \right)$$



1-c) on donne :

$$\pi(\theta) = \begin{cases} 2(1-\theta) & \text{si } 0 < \theta < 1 \\ 0 & \text{sinon} \end{cases}$$

Déterminons l'estimateur MAP de  $\theta$

$$L(\theta | y_i) = \prod_{i=1}^n \binom{y_i-1}{x_i-1} \theta^{x_i} (1-\theta)^{y_i-x_i}$$

\* Recherchons  $\pi$  à posteriori

$$\pi(\theta | y_i) = \frac{P(y_i | \theta, x_i) \pi(\theta)}{\int_{-\infty}^{\infty} P(y_i | \theta, x_i) d\theta}$$

$$\text{or } \int_{-\infty}^{\infty} P(y_i | \theta, x_i) d\theta = \text{constante} = c$$

$$\text{Posons } \frac{1}{c} = K = \text{constante}$$

$$\begin{aligned} \text{Alors } \pi(\theta | y_i) &= K \times P(y_i | \theta, x_i) \pi(\theta) \\ &= K \times \binom{y_i-1}{x_i-1} \theta^{x_i} (1-\theta)^{y_i-x_i} \times 2(1-\theta) \end{aligned}$$

$$\text{or } \hat{\theta}_{\text{MAP}} = \text{Arg max } \{ \pi(\theta | y_i) \}$$



$$= \text{Arg max} \left\{ \ln \left[ 2k \binom{y_i-1}{x_i-1} \theta^{x_i} (1-\theta)^{y_i-x_i+1} \right] \right\}$$

$$= \sum_{i=1}^n \text{Arg max} \left\{ c^{ste} + x_i \ln \theta + (y_i - x_i + 1) \ln(1-\theta) \right\}$$

$$\frac{\partial \mathcal{L}(\theta)}{\partial \theta} = 0 \Rightarrow \frac{1}{\theta} \sum_{i=1}^n x_i - \frac{1}{1-\theta} \sum_{i=1}^n (y_i - x_i + 1) = 0$$

$$\Leftrightarrow \frac{1}{\theta} \sum_{i=1}^n x_i = \frac{1}{1-\theta} \sum_{i=1}^n (y_i - x_i + 1)$$

$$(1-\theta) \sum_{i=1}^n x_i = \theta \sum_{i=1}^n (y_i - x_i + 1)$$

$$\sum_{i=1}^n x_i = \theta \left( \sum_{i=1}^n y_i + n \right)$$

$$\text{Donc } \theta_{\text{MAP}} = \frac{\sum_{i=1}^n x_i}{\sum_{i=1}^n y_i + n}$$

## C-2) Estimateur de Bayes

Considérons la fonction de perte quadratique.

$$\hat{\theta}_{\pi} = \arg \min_{\theta} E_{\pi} \left[ (\theta - \hat{\theta})^2 \mid y_1, \dots, y_n \right]$$

$$= E_{\pi} \left( \theta \mid y_1, \dots, y_n \right)$$



$$= \int_{-\infty}^{+\infty} \theta \pi(\theta | y_i) d\theta$$

On sait aussi que :

$$L(\theta) = \prod_{i=1}^n \binom{y_i-1}{x_i-1} \theta^{x_i} (1-\theta)^{y_i-x_i} \quad \text{qui}$$

est la fonction de vraisemblance

Sa fonction à posteriori est

$$\pi(\theta) = \text{Constante} \times \theta^{\sum x_i} \times (1-\theta)^{\sum (y_i - x_i) + 1}$$

posons  $\alpha - 1 = \sum_{i=1}^n x_i$  et  $\beta - 1 = \sum_{i=1}^n (y_i - x_i) + 1$

$\Rightarrow \alpha = \sum_{i=1}^n x_i + 1$  et  $\beta = \sum_{i=1}^n (y_i - x_i) + 2$

On observe donc que la distribution a priori est de type Beta

$$\beta = \left( \alpha = \sum_{i=1}^n x_i + 1 \text{ et } \beta = \sum_{i=1}^n (y_i - x_i) + 2 \right)$$

Pour une loi  $\text{Beta}(\alpha, \beta)$ , l'espérance est :

$$E(\pi(\theta | y_i)) = \frac{\alpha}{\alpha + \beta}$$

$$\begin{aligned} \Rightarrow E[\pi(\theta | y_i)] &= \frac{\sum_{i=1}^n x_i + 1}{\left(\sum_{i=1}^n x_i + 1\right) + \left(\sum_{i=1}^n (y_i - x_i) + 2\right)} \\ &= \frac{\sum_{i=1}^n x_i + 1}{\sum_{i=1}^n x_i + 1 + \sum_{i=1}^n y_i - \sum_{i=1}^n x_i + 2} \end{aligned}$$

$$E[\pi(\theta | y_i)] = \frac{\sum_{i=1}^n x_i + 1}{\sum_{i=1}^n y_i + 3}$$

Alors

$$\hat{\theta}_{\text{Bayes}} = \frac{\sum_{i=1}^n x_i + 1}{\sum_{i=1}^n y_i + 3}$$



## Comparaison entre $\hat{\theta}_{MAP}$ et $\hat{\theta}_{Bayes}$

$$\hat{\theta}_{map} = \frac{\sum_{i=1}^n x_i}{\sum_{i=1}^n y_i + 1}$$

$$\hat{\theta}_{Bayes} = \frac{\sum_{i=1}^n x_i + 1}{\sum_{i=1}^n y_i + 3}$$

•  $\hat{\theta}_{map}$  maximise la densité a posteriori, tandis que  $\hat{\theta}_{Bayes}$  est l'esperance de la distribution a posteriori.

• Par ailleurs l'estimateur de Bayes est légèrement plus régularisé, car l'ajout de (+1) au numérateur et (+2) au dénominateur, ce qui correspond à une forme de régularisation introduite par la distribution a priori.

En fin  $\hat{\theta}_{map}$  est plus concentré sur la valeur qui maximise la probabilité, alors que Bayes prend en compte la forme complète de la distribution.

Ces deux estimateurs tendent à donner des valeurs proches lorsque le nombre d'observation "n" est grand, car l'influence de la distribution a priori diminue par rapport à la vraisemblance basée sur les données.



## Question 2

$$\{(x_i, y_i); i=1, \dots, n\} \quad p=1 \quad \sum_{i=1}^n w_i = 1$$

2-a) Détermination de l'estimateur des moindres carrés  $\hat{\beta}$  défini par

$$\hat{\beta} = \arg \min_{\beta} R \quad S_1(\beta) \text{ ou } RSS_1(\beta) = \sum_{i=1}^n (y_i - \beta x_i)^2$$

$$\frac{\partial}{\partial \beta} RSS_1(\beta) = \frac{\partial}{\partial \beta} \left[ \sum_{i=1}^n (y_i - \beta x_i)^2 \right]$$

$$= 2 \left[ \sum_{i=1}^n [(-x_i)(y_i - \beta x_i)] \right]$$

$$= 2 \sum_{i=1}^n (x_i y_i - \beta x_i^2)$$

$$= 2 \sum_{i=1}^n x_i y_i + 2\beta \sum_{i=1}^n x_i^2$$

$$\frac{\partial}{\partial \beta} RSS_1(\beta) = 0 \Rightarrow \beta \sum_{i=1}^n x_i^2 = \sum_{i=1}^n x_i y_i$$

$$\text{ou } \hat{\beta} = \frac{\sum_{i=1}^n x_i y_i}{\sum_{i=1}^n x_i^2}$$

2-b) Détermination de  $\hat{\beta}_0$  et  $\hat{\beta}_1$

$$(\hat{\beta}_0, \hat{\beta}_1) = \arg \min_{\beta_0, \beta_1} RSS_2(\beta_0, \beta_1)$$



$$RSS_2(\beta_0, \beta_1) = \sum_{i=1}^n w_i (y_i - \beta_0 - \beta_1 x_i)^2$$

$$\frac{\partial RSS_2}{\partial \beta_0} = -2 \sum_{i=1}^n w_i (y_i - \beta_0 - \beta_1 x_i) = 0 \quad (1)$$

$$\frac{\partial RSS_2}{\partial \beta_1} = -2 \sum_{i=1}^n w_i x_i (y_i - \beta_0 - \beta_1 x_i) = 0 \quad (2)$$

De (1), on a :

$$\sum_{i=1}^n w_i (y_i - \beta_0 - \beta_1 x_i) = 0$$

$$\Rightarrow \sum_{i=1}^n w_i y_i - \beta_0 \sum_{i=1}^n w_i - \beta_1 \sum_{i=1}^n w_i x_i = 0 \quad (1)$$

De (2), on a :

$$\sum_{i=1}^n w_i x_i (y_i - \beta_0 - \beta_1 x_i) = 0$$

$$\sum_{i=1}^n w_i x_i y_i - \beta_0 \sum_{i=1}^n w_i x_i - \beta_1 \sum_{i=1}^n w_i x_i^2 = 0$$

$\sum_{i=1}^n w_i = 1$  alors posons :

$$\overline{X_w} = \sum_{i=1}^n w_i x_i \quad \text{et} \quad \overline{Y_w} = \sum_{i=1}^n w_i y_i$$

Donc  $\overline{Y}_w - \beta_0 - \beta_1 \overline{X}_w = 0$

De (2), on a aussi

$$\sum_{i=1}^n w_i x_i y_i - \beta_0 \overline{X}_w - \beta_1 \sum_{i=1}^n w_i x_i^2 = 0$$

si  $\beta_0 = \overline{Y}_w - \beta_1 \overline{X}_w$  alors

$$\sum_{i=1}^n w_i x_i y_i - (\overline{Y}_w - \beta_1 \overline{X}_w) \overline{X}_w + \beta_1 \sum_{i=1}^n w_i x_i^2$$

$$\sum_{i=1}^n w_i x_i y_i - \overline{Y}_w \overline{X}_w = \beta_1 \left( \sum_{i=1}^n w_i x_i^2 - \overline{X}_w^2 \right)$$

$$\beta_1 = \frac{\sum_{i=1}^n w_i x_i y_i - \overline{Y}_w \overline{X}_w}{\sum_{i=1}^n w_i x_i^2 - \overline{X}_w^2}$$

$$\beta_0 = \overline{Y} - \beta_1 \overline{X}_w$$